AgroSearch — Motor de Busca Inteligente

Relatório Técnico — Laboratório Prático 04: Desafio Integrador

Instituição: UNIPÊ | Disciplina: Tendências em Ciência da Computação (Tópicos Avançados — Recuperação de Informação / PLN) | Professor: Me. Ricardo Roberto de Lima

1. Contexto e Objetivo

A AgroTech Solutions possui uma base interna de manuais técnicos sobre agricultura sustentável, controle de pragas e irrigação. Este projeto entrega um protótipo funcional de motor de busca textual (AgroSearch), construído em Streamlit, que permite ao técnico digitar uma consulta e receber os trechos mais relevantes, ranqueados por relevância. Todo o núcleo de recuperação da informação — pipeline de pré-processamento, índice invertido e cálculo de TF-IDF — foi implementado do zero, sem uso de bibliotecas de alto nível como scikit-learn.

2. Arquitetura da Solução

A aplicação é organizada em três pilares integrados numa única interface Streamlit:

- **Fase 1 — Pipeline de Pré-processamento:** tokenização por expressão regular, normalização (minúsculas e remoção de acentos via unicodedata), remoção de stopwords em português e stemming rudimentar por corte de sufixos comuns (ex.: 'irrigação' → 'irrig'). Stemming e stopwords são ligados/desligados por checkboxes na barra lateral, e o vocabulário do índice é recalculado dinamicamente a cada mudança.
- **Fase 2 — Índice Invertido:** a partir dos tokens pré-processados de cada documento (índice direto Doc → Termos), constrói-se o índice invertido Termo → [IDs de Documentos], exibido em tabela JSON interativa.
- **Fase 3 — Busca e Ranqueamento TF-IDF:** a consulta do usuário passa pelo mesmo pipeline de pré-processamento; para cada termo da consulta calcula-se TF (frequência do termo no documento dividida pelo total de tokens do documento) e IDF (logaritmo de N/DF, onde N é o total de documentos e DF o número de documentos que contêm o termo). O score de cada documento é a soma dos TF-IDF de todos os termos da consulta; a tabela é ordenada do maior para o menor score, com o documento vencedor destacado em verde.

3. Fórmulas Utilizadas

Métrica	Fórmula
TF (Term Frequency)	TF(t, d) = contagem(t em d) / total de tokens em d
IDF (Inverse Document Frequency)	IDF(t) = ln(N / DF(t))
TF-IDF	TF-IDF(t, d) = TF(t, d) × IDF(t)
Score do documento (query multi-termo)	Score(d) = Σ TF-IDF(t, d), para cada termo t da query
Bônus — Similaridade de Cosseno	cos(q, d) = (q · d) / (||q|| × ||d||), vetores TF-IDF sobre o vocabulário

4. Base de Documentos Utilizada

Os cinco documentos hardcoded sugeridos pelo desafio (Doc1 a Doc5), todos sobre práticas agrícolas (irrigação da soja, controle biológico de lagartas, adubação verde, lagartas desfolhadoras e irrigação por gotejamento), formam a coleção de teste, editável diretamente na interface.

5. Recurso Bônus — Similaridade de Cosseno

Para consultas com múltiplos termos, a aplicação oferece um modo alternativo de ranqueamento baseado em similaridade de cosseno: a query é tratada como um pseudo-documento e convertida em um vetor TF-IDF sobre todo o vocabulário; a similaridade com cada documento é o cosseno do ângulo entre os dois vetores. Esse modo lida melhor com consultas de múltiplas palavras do que a simples soma de TF-IDF, pois normaliza pelo tamanho dos vetores.

6. Validação

O pipeline foi validado manualmente: para a consulta 'irrigação soja', o Doc1 ('A soja requer irrigação constante...') obteve o maior score TF-IDF acumulado, seguido do Doc5 (irrigação por gotejamento) e do Doc2 (soja, sem menção a irrigação) — resultado coerente com a relevância semântica esperada.

7. Equipe

Integrante	Responsabilidade
Augusto Lustosa	Pipeline de pré-processamento (Fase 1) — tokenização, normalização, stopwords e stemming; Índice Invertido (Fase 2); integração geral da interface Streamlit.
Vitor Nóbrega de Souza	Busca e Ranqueamento por TF-IDF (Fase 3) — cálculo de TF, IDF e TF-IDF; recurso bônus de Similaridade de Cosseno; elaboração deste relatório técnico.